

Roteiro do vídeo: Pipeline de Agentes com CrewAI: qualificação de leads e e-mail de vendas

Item	Detalhe
Notebook	pipeline_de_agentes.ipynb (executado, com todas as saídas)
Cenas	37, cada uma com uma tela capturada do Jupyter (1920×1080, pasta telas/)
Narração	1285 palavras, em tom de aula
Duração estimada	9 min 10 s (~150 palavras/min + 1 s de pausa por cena)
Fonte para montar o vídeo	roteiro.json (tela, narração, início e duração de cada cena)
Revisão	Todas as telas foram conferidas contra a narração (números, nomes e trechos citados)

Roteiro cena a cena

Cena 01Abertura

0:00 → 0:25 · 25 s



Na tela: Título e a lista de 5 passos do pipeline telas/01_abertura.png

Olá! Nesta aula vamos ver um pipeline comercial feito só com agentes de IA, usando o CrewAI, uma biblioteca Python para criar equipes de agentes. A partir de um lead, uma pessoa interessada no nosso produto, os agentes pesquisam a pessoa e a empresa na internet, dão uma nota e, se ela for boa, escrevem um e-mail de vendas personalizado.

4. Filtra só os leads bons (nota acima de 70).
5. Escreve um e-mail de vendas personalizado para cada lead aprovado e depois **otimiza** esse e-mail para gerar resposta.

Ao todo são **5 agentes**, organizados em **2 equipes (crews)** e coordenados por um **Flow**:

```
graph LR
    buscar_leads --> Especialista
    subgraph Crew1 [Crew 1: Qualificação de Leads]
        Especialista --> Analista
        Analista --> Avaliador
    end
    Avaliador --> filtrar_leads
    filtrar_leads --> escrever_email
    subgraph Crew2 [Crew 2: Engajamento por E-mail]
        Redator --> EspecialistaEngajamento
    end
    escrever_email --> Redator
    Redator --> enviar_email
```

Conceitos do CrewAI que aparecem aqui

Conceito	O que é
Agent (Agente)	Um "funcionário" de IA com papel (<code>role</code>), objetivo (<code>goal</code>) e história (<code>backstory</code>). Usa um LLM para pensar.
Task (Tarefa)	O trabalho que um agente precisa fazer, com descrição e resultado esperado.
Tool (Ferramenta)	Algo que o agente pode usar além do LLM, como buscar no Google ou ler um site.
Crew (Equipe)	Um grupo de agentes executando uma sequência de tarefas.
Flow (Fluxo)	Orquestra várias etapas (e várias crews) com código Python, decidindo o que roda depois de quê.

Este material é uma adaptação, traduzida e comentada, de uma aula do curso *Practical Multi AI Agents and Advanced Use Cases with crewAI* (DeepLearning.AI + CrewAI).

1. Pré-requisitos: ambiente e chaves de API

Ambiente Python

O notebook foi testado num ambiente Conda com Python 3.12 e CrewAI 1.15. Para recriar:

```
conda create -n aulaagentes python=3.12 -y
conda activate aulaagentes
pip install -r requirements.txt
jupyter notebook
```

Na tela: Diagrama das duas crews e a tabela de conceitos telas/02_arquitetura_conceitos.png

São cinco agentes em duas equipes. Guarde cinco conceitos: agente é um assistente de IA com um papel definido; tarefa é o trabalho dado a ele; ferramenta é algo que ele usa além do próprio conhecimento, como uma busca no Google; crew é uma equipe de agentes; e flow é o roteiro que diz o que roda primeiro e o que vem depois.

1. Pré-requisitos: ambiente e chaves de API

Ambiente Python

O notebook foi testado num ambiente Conda com Python 3.12 e CrewAI 1.15. Para recriar:

```
conda create -n aulaagentes python=3.12 -y
conda activate aulaagentes
pip install -r requirements.txt
jupyter notebook
```

Chaves de API: cada aluno precisa criar as suas, com crédito

Os agentes usam dois serviços pagos. **Sem uma chave válida e com saldo, o notebook não funciona.**

Serviço	Para que serve	Onde criar a chave
DeepSeek	É o LLM, o "cérebro" dos agentes	https://platform.deepseek.com/api_keys (é preciso colocar crédito na conta; alguns dólares bastam para muitas execuções)
Serper	Faz buscas no Google para os agentes	https://serper.dev/api-key (a conta nova vem com créditos gratuitos de busca)

As chaves **nunca** devem ficar escritas no notebook: se o notebook for compartilhado, a chave vaza junto. Por isso elas ficam num arquivo separado chamado `.env`, na mesma pasta deste notebook:

- Copie o arquivo `.env.exemplo` para `.env`.
- Abra o `.env` e troque `coloque_sua_chave_aqui` pelas suas chaves.
- Não envie o `.env` para ninguém nem para o GitHub (ele já está no `.gitignore`).


Quer usar outro LLM? O CrewAI aceita vários provedores. Basta mudar a variável `MODELO_LLM` no `.env`, por exemplo `openai/gpt-4o-mini` (com `OPENAI_API_KEY`) ou `anthropic/claude-sonnet-4-5` (com `ANTHROPIC_API_KEY`).

2. Conferindo as versões instaladas

Primeiro verificamos se as bibliotecas principais estão instaladas e em que versão. Isso ajuda a diagnosticar problemas: o CrewAI muda bastante entre

Na tela: Tabela DeepSeek / Serper e os passos do arquivo .env telas/03_prerequisitos_chaves.png

Os agentes usam dois serviços: o DeepSeek, que fornece o LLM, o modelo de linguagem que lê e escreve texto, e o Serper, que busca no Google. Cada um exige uma chave de API, uma senha que identifica a sua conta e desconta os créditos dela. Cada aluno cria as suas, e elas ficam no arquivo ponto env, nunca no notebook.




Na tela: Saída: CrewAI 1.15.22 e Pydantic 2.12.5 telas/04_versoes.png

A primeira célula confere as versões: CrewAI um ponto quinze e Pydantic dois. Isso ajuda quando algo dá errado, porque o CrewAI muda bastante entre versões.



Na tela: `load_dotenv(".env")` e o import de Agent, Task, Crew, LLM telas/05_importacoes_env.png

O destaque das importações é o `load_dotenv`: ele lê o ponto `env` e cria variáveis de ambiente, configurações que o programa enxerga sem que apareçam no código. É ali que o CrewAI busca as chaves.



The screenshot shows a JupyterLab window titled 'pipeline_de_agentes' with a 'Last Checkpoint: 1 hour ago' status. The interface includes a menu bar (File, Edit, View, Run, Kernel, Settings, Help) and a toolbar. The main area displays a code cell with the following content:

4. Verificando as chaves e configurando o LLM

Esta célula **não mostra** as chaves. Ela só confere se elas foram carregadas do `.env`; se faltar alguma, avisa o que fazer.

Depois criamos o objeto `llm`, que é o modelo de linguagem usado por todos os agentes. O nome do modelo vem da variável `MODELO_LLM` do `.env` (por padrão, `deepseek/deepseek-v4-flash`; o prefixo antes da barra diz ao CrewAI qual é o provedor).

```
[3]: chaves_necessarias = ["DEEPSEEK_API_KEY", "SERPER_API_KEY"]
faltando = [chave for chave in chaves_necessarias
             if not os.getenv(chave) or "coloque_sua_chave" in os.getenv(chave)]

if faltando:
    raise RuntimeError(
        f"Chaves não configuradas: {faltando}. "
        "Copie .env.exemplo para .env e preencha com as SUAS chaves (com crédito)."
    )
print("Chaves carregadas do .env:", ", ".join(chaves_necessarias))

# 0 "cérebro" dos agentes
llm = LLM(
    model=os.getenv("MODELO_LLM", "deepseek/deepseek-v4-flash"),
    api_key=os.getenv("DEEPSEEK_API_KEY"),
    temperature=0.3,
)
print("Modelo em uso:", llm.model)

Chaves carregadas do .env: DEEPSEEK_API_KEY, SERPER_API_KEY
Modelo em uso: deepseek-v4-flash
```

5. Carregando agentes e tarefas dos arquivos YAML


Em vez de escrever os textos dos agentes e tarefas no meio do código, o CrewAI permite guardá-los em arquivos **YAML** na pasta `config/`. Isso deixa o código limpo e facilita ajustar os textos (*prompts*) sem mexer no Python.

Arquivo	Conteúdo
agentes_qualificacao_leads.yaml	Os 3 agentes que pesquisam e pontuam o lead
tarefas_qualificacao_leads.yaml	As 3 tarefas desses agentes

Na tela: Saída das chaves carregadas, modelo deepseek-v4-flash e temperature=0.3


telas/06_chaves_llm.png

Aqui conferimos se as chaves foram carregadas, sem exibi-las, e criamos o LLM, o deepseek v4 flash. O temperature baixo deixa as respostas mais previsíveis.



Na tela: Tabela com os 4 arquivos e a tabela de campos (role, goal, backstory, description, expected_output) telas/07_yaml_explicacao.png

Os textos dos agentes e das tarefas ficam em arquivos YAML, um formato de texto simples com pares nome e valor. Cada agente tem role, o papel; goal, o objetivo; e backstory, a história que lhe dá experiência e personalidade. Cada tarefa tem description, o que fazer, e expected output, como entregar. Tudo isso vira instrução para o modelo.



Na tela: Saída com os nomes dos 5 agentes telas/08_yaml_carregamento.png

O código abre os quatro arquivos e guarda cada um num dicionário. A saída confirma os cinco agentes: três de qualificação e dois de e-mail.

```
jupyter agentes_qualificacao_leads.yaml Last Checkpoint: 2 hours ago
File Edit View Settings Help

1 # Agentes da equipe (crew) de QUALIFICAÇÃO DE LEADS
2 # Cada agente tem: role (papel), goal (objetivo) e backstory (história/personalidade).
3
4 agente_dados_lead:
5   role: >
6     Especialista em Dados de Leads
7   goal: >
8     Levantar e analisar informações pessoais e da empresa de cada lead.
9   backstory: >
10     Você é um especialista em dados, muito atento aos detalhes, responsável por
11     reunir e analisar informações sobre a pessoa e sobre a empresa para
12     descobrir o potencial de cada lead. Você sempre responde em português do Brasil.
13   verbose: true
14   allow_delegation: false
15
16 agente_fit_cultural:
17   role: >
18     Analista de Afinidade Cultural
19   goal: >
20     Avaliar o alinhamento cultural entre a empresa do lead e a nossa
21     organização, e medir o encaixe geral entre as duas.
22   backstory: >
23     Você é especialista em entender a cultura e os valores das empresas,
24     garantindo que as parcerias sejam não só estratégicas, mas também
25     culturalmente alinhadas para dar certo no longo prazo.
26     Você sempre responde em português do Brasil.
27   verbose: true
28   allow_delegation: false
29
30 agente_pontuacao_validacao:
31   role: >
32     Avaliador e Validador de Leads
33   goal: >
34     Consolidar os dados levantados, atribuir uma nota ao lead com base em
35     critérios definidos e validar se essa nota está correta.
36   backstory: >
37     Você é especialista em medir a qualidade de leads por meio de análise de
38     dados e em garantir que o processo de pontuação seja preciso e confiável.
39     Você sempre responde em português do Brasil.
40   verbose: true
41   allow_delegation: false
```

Na tela: role, goal e backstory do Especialista em Dados de Leads telas/09_yaml_agentes.png


Por dentro, o especialista em dados tem papel, objetivo e uma história que o descreve como detalhista: é a descrição do cargo, que orienta como ele pensa. O verbose mostra o raciocínio na tela, e o allow delegation falso impede que ele repasse o trabalho.

```
jupyter tarefas_qualificacao_leads.yaml
File Edit View Settings Help

1 # Tarefas da equipe (crew) de QUALIFICAÇÃO DE LEADS
2 # {dados_lead} é substituído pelos dados de cada lead quando a crew é executada.
3
4 coleta_dados_lead:
5   description: >
6     Pesquise na internet e analise as seguintes informações sobre o lead:
7
8     - Informações pessoais:
9       - Nome: o nome completo do lead.
10      - Cargo: o cargo atual do lead.
11      - Relevância do cargo: o quanto o cargo do lead pesa na decisão de compra, numa escala de 0 a 10.
12      - Histórico profissional: opcionalmente, um breve resumo da trajetória profissional do lead.
13
14     - Informações da empresa:
15       - Nome da empresa: a empresa onde o lead trabalha.
16       - Setor: o setor de atuação da empresa.
17       - Porte: o número aproximado de funcionários.
18       - Faturamento: se disponível, o faturamento anual da empresa.
19       - Presença de mercado: a força da empresa no mercado, numa escala de 0 a 10.
20
21     - Nossa empresa e nosso produto:
22       - Empresa: CrewAI
23       - Produto: Plataforma de Orquestração de Múltiplos Agentes
24       - Cliente ideal (ICP): grandes empresas interessadas em automação com agentes de IA.
25       - Proposta: somos uma plataforma que permite orquestrar agentes de IA para automatizar processos em qualquer setor.
26
27     - Dados do lead:
28       {dados_lead}
29   expected_output: >
30     Um relatório completo, em português, contendo:
31     - Informações pessoais (nome, cargo, relevância do cargo e, se houver, histórico profissional).
32     - Informações da empresa (nome, setor, porte, faturamento se disponível e presença de mercado).
33
34 analise_fit_cultural:
35   description: >
36     Avalie o alinhamento cultural entre a empresa do lead e a nossa organização, considerando:
37     - Valores culturais: analise os valores divulgados publicamente e a cultura interna da empresa (por exemplo: inovação, sustentabilidade,
38     engajamento dos funcionários).
39     - Alinhamento estratégico: avalie o quanto os objetivos e a missão da empresa combinam com os objetivos estratégicos da nossa organização.
40     - Nota qualitativa: atribua uma nota de 0 a 10 para o encaixe cultural geral.
41     - Comentários: acrescente observações que justifiquem a nota.
```

Na tela: description, expected_output e a variável {dados_lead} telas/09b_yaml_tarefas.png

No arquivo de tarefas, a description é a ordem de serviço, com o que pesquisar, e o expected output descreve o relatório a entregar. O dados lead entre chaves é uma variável: na execução, o CrewAI troca esse trecho pelos dados do lead.



Na tela: Explicação de output_pydantic e os três blocos telas/10_pydantic_explicacao.png

LLMs respondem em texto livre, que é difícil de usar num programa. Por isso usamos o Pydantic, uma biblioteca Python para descrever e validar estruturas de dados: dizemos quais campos a resposta deve ter, de que tipo e com que limites.




Na tela: Classes do Pydantic, Field e os limites ge/le telas/11_pydantic_codigo.png

Cada classe é um molde: dados pessoais, dados da empresa e pontuação, e uma quarta classe junta tudo. O Field descreve cada campo, e os limites ge e le, maior ou igual e menor ou igual, garantem, por exemplo, nota entre zero e cem. Assim a resposta vira um objeto Python.




Na tela: SerperDevTool e ScrapeWebsiteTool telas/12_ferramentas.png

As ferramentas são as mãos dos agentes: o SerperDevTool busca no Google, e o ScrapeWebsiteTool lê o texto de uma página, o chamado scraping. É o próprio agente que decide quando usar cada uma.



Na tela: Tabela dos 3 agentes e o parâmetro context telas/13_crew1_explicacao.png

A primeira equipe tem o especialista em dados, o analista de afinidade cultural, que avalia se a empresa combina com a nossa, e o avaliador, que dá a nota. O context faz o avaliador receber o resultado dos colegas: é assim que um agente usa o trabalho do outro.



```
[7]: # --- Agentes ---
agente_dados_lead = Agent(
    config=config.agentes_leads['agente_dados_lead'],
    tools=[ferramenta_busca, ferramenta_leitura],
    llm=llm,
)

agente_fit_cultural = Agent(
    config=config.agentes_leads['agente_fit_cultural'],
    tools=[ferramenta_busca, ferramenta_leitura],
    llm=llm,
)

agente_pontuacao_validacao = Agent(
    config=config.agentes_leads['agente_pontuacao_validacao'],
    tools=[ferramenta_busca, ferramenta_leitura],
    llm=llm,
)

# --- Tarefas ---
tarefa_dados_lead = Task(
    config=config.tarefas_leads['coleta_dados_lead'],
    agent=agente_dados_lead,
)


tarefa_fit_cultural = Task(
    config=config.tarefas_leads['analise_fit_cultural'],
    agent=agente_fit_cultural,
)

tarefa_pontuacao_validacao = Task(
    config=config.tarefas_leads['pontuacao_e_validacao_lead'],
    agent=agente_pontuacao_validacao,
    context=[tarefa_dados_lead, tarefa_fit_cultural], # recebe o resultado das duas anteriores
    output_pydantic=ResultadoQualificacaoLead, # saída estruturada
)

# --- Equipe ---
crew_qualificacao_leads = Crew(
    agents=[agente_dados_lead, agente_fit_cultural, agente_pontuacao_validacao],
    tasks=[tarefa_dados_lead, tarefa_fit_cultural, tarefa_pontuacao_validacao],
)
```

Na tela: context=[...] e output_pydantic na terceira tarefa telas/14_crew1_codigo.png

Cada agente recebe a configuração do YAML, as ferramentas e o LLM, e cada tarefa é ligada ao seu agente. Na última estão o context e o output pydantic, que obriga a resposta a seguir o nosso molde. A Crew reúne tudo.



```
9. Crew 2: engajamento por e-mail (2 agentes, 2 tarefas)

A segunda equipe recebe o lead já qualificado e escreve o e-mail:

1. O Redator de E-mails escreve um rascunho personalizado com os dados pesquisados.
2. O Especialista em Engajamento revisa o rascunho e acrescenta chamadas para ação (CTAs), como "agende uma conversa de 20 minutos".

Esses agentes não precisam de ferramentas: todas as informações já vêm prontas da crew anterior. As tarefas rodam em sequência, e a segunda recebe automaticamente o resultado da primeira.

[8]: # --- Agentes ---
especialista_conteudo_email = Agent(
    config=config.agentes_email['especialista_conteudo_email'],
    llm=llm,
)

estrategista_engajamento = Agent(
    config=config.agentes_email['estrategista_engajamento'],
    llm=llm,
)

# --- Tarefas ---
tarefa_redacao_email = Task(
    config=config.tarefas_email['redacao_email'],
    agent=especialista_conteudo_email,
)

tarefa_otimizacao_engajamento = Task(
    config=config.tarefas_email['otimizacao_engajamento'],
    agent=estrategista_engajamento,
)

# --- Equipe ---
crew_redacao_email = Crew(
    agents=[especialista_conteudo_email, estrategista_engajamento],
    tasks=[tarefa_redacao_email, tarefa_otimizacao_engajamento],
    verbose=True,
)
```

Na tela: Redator e Especialista em Engajamento, sem ferramentas telas/15_crew2.png

A segunda equipe escreve o e-mail: o redator faz o rascunho, e o especialista em engajamento acrescenta CTAs, as chamadas para ação, como um convite para reunião. Eles não usam ferramentas: os dados já chegam prontos.

10. O Flow: juntando tudo num pipeline de vendas

Um **Flow** é uma classe Python em que cada método é uma etapa do processo. Os **decoradores** dizem a ordem:

- `@start()`: a etapa que começa o fluxo.
- `@listen(etapa)`: roda quando a `etapa` indicada termina, recebendo o resultado dela.

Nosso fluxo:

Etapa	O que faz
buscar_leads	Devolve a lista de leads. Aqui é uma lista fixa de exemplo; num sistema real viria do banco de dados ou do CRM.
pontuar_leads	Roda a crew de qualificação para cada lead (<code>kickoff_for_each</code>) e guarda os resultados no estado do fluxo (<code>self.state</code>).
armazenar_pontuacoes	Lugar para salvar as notas no banco de dados (aqui só devolve).
filtrar_leads	Mantém só os leads com nota maior que 70 .
escrever_email	Roda a crew de e-mail para cada lead aprovado.
enviar_email	Lugar para enviar os e-mails de verdade (aqui só devolve).

Sobre o lead de exemplo: a pessoa (**Carla Mendes**) e o e-mail são **fictícios**. A empresa é real, para que os agentes tenham o que pesquisar na internet. Troque pelos dados que quiser.

```
[9]: from crewai import Flow
from crewai.flow.flow import listen, start

class PipelineVendas(Flow):

    @start()
    def buscar_leads(self):
        # Num sistema real, os leads viriam do banco de dados / CRM
        leads = [
            {
                "dados_lead": {
                    "nome": "Carla Mendes (pessoa ficticia)",
                    "cargo": "Diretora de Engenharia",
                    "empresa": "Nubank",
                    "email": "carla.mendes@exemplo.com.br",
                    "caso_de_uso": "Usar agentes de IA para automatizar o atendimento ao cliente e a análise de dados.",
                }
            },
        ]
        return leads

    @listen(buscar_leads)
    def pontuar_leads(self, leads):
        resultados = crew_qualificacao_leads.kickoff_for_each(leads)
        self.state["resultados_qualificacao"] = resultados
        return resultados

    @listen(pontuar_leads)
    def armazenar_pontuacoes(self, resultados):
        # Aqui salvaríamos as notas no banco de dados
        return resultados

    @listen(pontuar_leads)
    def filtrar_leads(self, resultados):
        return [r for r in resultados if r['pontuacao_lead'].pontuacao > 70]

    @listen(filtrar_leads)
    def escrever_email(self, leads):
        leads_pontuados = [lead.to_dict() for lead in leads]
        emails = crew_redacao_email.kickoff_for_each(leads_pontuados)
        return emails
```

Na tela: `@start`, `@listen` e a tabela de etapas `telas/16_flow_explicacao.png`

O Flow junta as equipes. Cada método é uma etapa, e a ordem vem dos decoradores, as marcações com arroba sobre a função: `start` marca o início, e `listen` faz uma etapa começar quando outra termina. O lead é uma pessoa fictícia, numa empresa real.

```
[9]: from crewai import Flow
from crewai.flow.flow import listen, start

class PipelineVendas(Flow):

    @start()
    def buscar_leads(self):
        # Num sistema real, os leads viriam do banco de dados / CRM
        leads = [
            {
                "dados_lead": {
                    "nome": "Carla Mendes (pessoa ficticia)",
                    "cargo": "Diretora de Engenharia",
                    "empresa": "Nubank",
                    "email": "carla.mendes@exemplo.com.br",
                    "caso_de_uso": "Usar agentes de IA para automatizar o atendimento ao cliente e a análise de dados.",
                }
            },
        ]
        return leads

    @listen(buscar_leads)
    def pontuar_leads(self, leads):
        resultados = crew_qualificacao_leads.kickoff_for_each(leads)
        self.state["resultados_qualificacao"] = resultados
        return resultados

    @listen(pontuar_leads)
    def armazenar_pontuacoes(self, resultados):
        # Aqui salvaríamos as notas no banco de dados
        return resultados

    @listen(pontuar_leads)
    def filtrar_leads(self, resultados):
        return [r for r in resultados if r['pontuacao_lead'].pontuacao > 70]


    @listen(filtrar_leads)
    def escrever_email(self, leads):
        leads_pontuados = [lead.to_dict() for lead in leads]
        emails = crew_redacao_email.kickoff_for_each(leads_pontuados)
        return emails
```

Na tela: `buscar_leads` → `pontuar_leads` → `filtrar_leads` (`> 70`) → `escrever_email`
`telas/17_flow_codigo.png`

O caminho: buscar os leads; pontuar cada um com a primeira equipe, usando o `kickoff for each`, e guardar o resultado no state, a memória compartilhada do fluxo; filtrar quem tem nota acima de setenta; e escrever o e-mail com a segunda equipe.

Cena 19 Diagrama do fluxo

5:30 → 5:38 · 8 s



Na tela: Caixas e setas: quem escuta quem `telas/19_diagrama_fluxo.png`

O CrewAI desenha o fluxo: cada caixa é uma etapa, e cada seta mostra quem escuta quem.

Cena 20 Executando o pipeline

5:38 → 5:52 · 14 s

```
12. Executando o pipeline

Agora rodamos o fluxo inteiro. Como o Jupyter já tem um "laço assíncrono" em execução, usamos await fluxo.kickoff_async().

Isso leva alguns minutos. Com verbose=True você vai ver cada agente:



- recebendo a tarefa,
- decidindo buscar no Google ou ler um site,
- analisando os resultados,
- entregando a resposta final.



Cada execução gasta créditos do LLM e das buscas: o custo é pequeno, mas não é zero.

[11]: emails = await fluxo.kickoff_async()
```

Flow Execution


Starting Flow Execution
Name: PipelineVendas
ID: 8016527d-2e6c-4851-9e2b-ffae006985

Flow Started

Flow Started
Name: PipelineVendas
ID: 8016527d-2e6c-4851-9e2b-ffae006985

Na tela: `await fluxo.kickoff_async()` e o início do fluxo `telas/20_execucao_inicio.png`

Hora de rodar. Usamos `await` com `kickoff async` porque o Jupyter é assíncrono: espera uma operação demorada sem travar. Leva alguns minutos, e o `verbose` mostra tudo o que os agentes fazem.




Na tela: Painéis 'Crew Execution Started' e 'Task Started' telas/21_exec_crew_iniciada.png

A equipe recebe a primeira tarefa, e a variável dados lead já foi trocada pelos dados do lead.



Na tela: 'Agent Started' e o primeiro 'Tool Execution Started' telas/22_exec_agente_dados.png

O especialista em dados decide sozinho usar a busca: pesquisa setor, funcionários e faturamento do Nubank.




```
Tool: search_the_internet_with_serper
Args: {'search_query': 'Nubank empresa setor número de funcionários faturamento'}

Tool: search_the_internet_with_serper
Args: {'search_query': 'Nubank revenue 2024 employees fintech Brazil'}

Tool Completed
Tool: search_the_internet_with_serper
Output: {'searchParameters': {'q': 'Nubank empresa setor número de funcionários faturamento', 'type': 'search', 'num': 10, 'engine': 'google'}, 'organic': [{'title': 'Conta Nu Empresas', 'link': 'https://nubank.com.br/empresas/conta', 'snippet': 'Conta Nu Empresas com sócios e funcionários e atribua perfis para cada um deles de acordo com as suas funções.', 'position': 1}, {'title': 'Sobre o Nubank', 'link': 'https://nu.com/pt/que-somos', 'snippet': 'O Nubank, maior banco digital da América Latina, atende a 135M clientes e vem liderando uma transformação na indústria. Saiba mais.', 'position': 2}, {'title': 'Cartão Nu Empresas', 'link': 'https://nubank.com.br/empresas/cartao', 'snippet': 'Benefícios do Cartão Nu Empresas - Mais opções de crédito - Fácil gestão de gastos - Sem anuidade e atendimento 24h.', 'position': 3}, {'title': 'Nubank - Wikipédia, a enciclopédia livre', 'link': 'https://pt.wikipedia.org/wiki/Nubank', 'snippet': 'É o maior banco fintech da América Latina e o maior banco digital em número de clientes fora da Ásia, com mais de 135 milhões de clientes alcançados em março de ...', 'position': 4}, {'title': 'Contrato e regulamento conta Nu Empresas', 'link': 'https://nubank.com.br/contratos/contrato-de-conta-nu-empresas', 'snippet': 'Nu Empresas permite a concessão de diferentes níveis de acesso a sócios e funcionários da empresa por meio do Acesso Compartilhado.', 'position': 5}, {'title': 'O Nubank demitiu 12 funcionários após reunião interna ...', 'link': 'https://www.instagram.com/p/DQ4tVVCzBL/', 'snippet': 'Nubank demitiu 12 funcionários - de 7
```

Na tela: Resultado da busca: links e trechos reais telas/23_exec_ferramenta_busca.png

Aqui estão as buscas e um resultado: títulos, links e trechos reais, vindos do Google.



```
[Finalize] todos_count=0, todos_with_results=0

Agent: Especialista em Dados de Leads

Final Answer:
# Relatório de Análise de Lead

> **Observação importante de verificação:** Conforme informado nos dados de entrada, o nome ***Carla Mendes*** está explicitamente marcado como pessoa fictícia** no cadastro do lead. Portanto, não há registros públicos verificáveis sobre essa pessoa (cargo, histórico profissional ou vínculos reais). As informações pessoais abaixo devem ser tratadas como dados hipotéticos/declarados no formulário do lead, não como fatos confirmados por fontes externas. Todas as informações da **empresa (Nubank)** foram verificadas em fontes públicas e reais, e são apresentadas com base nelas.

---

## 1. Informações Pessoais

| Campo | Informação |
|---|---|
| **Nome** | Carla Mendes *(marcada como pessoa fictícia nos dados do lead - não verificável publicamente)* |
| **Cargo** | Diretora de Engenharia (declarado no lead) |
| **Relevância do cargo (0-10)** | **9/10** |
| **Histórico profissional** | Não disponível/não verificável, pois trata-se de pessoa fictícia. |


### Análise da relevância do cargo
O cargo de **Diretora de Engenharia** é altamente relevante para o processo de decisão de compra do produto da CrewAI (Plataforma de Orquestração de Múltiplos Agentes). Justificativa:

- **Poder de influência técnica elevado (decisor/influenciador-chave):** Diretores de Engenharia são responsáveis por definir a arquitetura técnica, a stack de tecnologia e as ferramentas de desenvolvimento usadas pela empresa. A adoção de uma plataforma de orquestração de agentes de IA passa diretamente pelo crivo dessa liderança.
- **Orçamento técnico:** Em empresas de tecnologia maduras, o setor de Engineering costuma ter autonomia (ou forte influência) sobre o orçamento de ferramentas de desenvolvimento e infraestrutura de IA.
- **Caso de uso perfeitamente alinhado:** O caso de uso declarado - automatizar atendimento ao cliente e análise de dados com agentes de IA - é uma dor natural e prioritária de uma Diretoria de Engenharia em uma fintech de grande porte.
- **Poder de veto:** Mesmo quando a decisão final é de um C-level (CTO/CEO), o endosso positivo de um Diretor de Engenharia é praticamente condição necessária.

**Pontuação: 9/10** - o cargo é praticamente um decisor/influenciador de altíssima relevância, ficando abaixo de 10 apenas por não ser, necessariamente, o detentor final do orçamento (papel que normalmente cabe ao CTO ou CFO).
```

Na tela: 'Agent Final Answer': relatório de análise do lead telas/24_exec_resposta_dados.png

A resposta final é um relatório em português. O agente percebeu que a pessoa é fictícia e não inventou dados: só confirmou o que é público sobre a empresa.



```
Agent: Analista de Afinidade Cultural

Task: Avalie o alinhamento cultural entre a empresa do lead e a nossa organização, considerando:
- Valores culturais: analise os valores divulgados publicamente e a cultura interna da empresa (por exemplo: inovação, sustentabilidade, engajamento dos funcionários).
- Alinhamento estratégico: avalie o quanto os objetivos e a missão da empresa combinam com os objetivos estratégicos da nossa organização.
- Nota qualitativa: atribua uma nota de 0 a 10 para o encaixe cultural geral.
- Comentários: acrescente observações que justifiquem a nota.

- Nossa empresa e nosso produto:
- Empresa: CrewAI
- Produto: Plataforma de Orquestração de Múltiplos Agentes
- Cliente ideal (ICP): grandes empresas interessadas em automação com agentes de IA.
- Proposta: somos uma plataforma que permite orquestrar agentes de IA para automatizar processos em qualquer setor.


- Dados do lead:
{'nome': 'Carla Mendes (pessoa fictícia)', 'cargo': 'Diretora de Engenharia', 'empresa': 'Nubank', 'email': 'carla.mendes@exemplo.com.br', 'caso_de_uso': 'Usar agentes de IA para automatizar o atendimento ao cliente e a análise de dados.'}

Tool Execution Started (#4)

Tool: search_the_internet_with_serper
Args: {'search_query': 'Nubank cultura valores empresa inovação sustentabilidade funcionários'}
```

Na tela: Busca por cultura e valores da empresa telas/25_exec_agente_afinidade.png

O analista de afinidade pesquisa cultura e valores. Cada agente busca de acordo com o papel descrito no YAML.



```
Agent: Avaliador e Validador de Leads

Task: Consolide os dados levantados e siga estes passos: - Cálculo da nota: com base em critérios definidos, calcule a nota final do lead (0 a 100). Considere fatores como:
- Relevância do cargo
- Porte da empresa
- Presença de mercado
- Afinidade cultural
- Documentação dos critérios: liste os critérios usados para chegar à nota. - Validação: revise os dados levantados e a nota calculada, verificando se estão consistentes e corretos. Faça ajustes se necessário. - Relatório final: monte um resumo com a nota final validada, os critérios usados e as observações da validação.

- Nossa empresa e nosso produto:
- Empresa: CrewAI
- Produto: Plataforma de Orquestração de Múltiplos Agentes
- Cliente ideal (ICP): grandes empresas interessadas em automação com agentes de IA.
- Proposta: somos uma plataforma que permite orquestrar agentes de IA para automatizar processos em qualquer setor.

- Dados do lead:
{'nome': 'Carla Mendes (pessoa fictícia)', 'cargo': 'Diretora de Engenharia', 'empresa': 'Nubank', 'email': 'carla.mendes@exemplo.com.br', 'caso_de_uso': 'Usar agentes de IA para automatizar o atendimento ao cliente e a análise de dados.'}


[Finalize] todos_count=0, todos_with_results=0

Agent: Avaliador e Validador de Leads

Final Answer:
{
  "dados_pessoais": {
    "nome": "Carla Mendes (pessoa fictícia)",
    "cargo": "Diretora de Engenharia",
    "empresa": "Nubank",
    "email": "carla.mendes@exemplo.com.br",
    "caso_de_uso": "Usar agentes de IA para automatizar o atendimento ao cliente e a análise de dados."
  },
  "nota_final": 85,
  "observacoes": "Avaliação baseada nos critérios de relevância do cargo, porte da empresa, presença de mercado e afinidade cultural. A documentação dos critérios e a validação dos dados foram realizadas com sucesso."
}
```

Na tela: Avaliador e Validador de Leads recebe o contexto telas/26_exec_avaliador.png

O avaliador recebe, pelo context, o trabalho dos dois colegas e consolida tudo numa nota.



```
[Finalize] todos_count=0, todos_with_results=0

Agent: Avaliador e Validador de Leads

Final Answer:
{
  "dados pessoais": {
    "nome": "Carla Mendes (pessoa fictícia)",
    "cargo": "Diretora de Engenharia",
    "relevancia cargo": 9,
    "historico profissional": "Não disponível/não verificável. O lead 'Carla Mendes' está explicitamente marcado como pessoa fictícia nos dados de cadastro (e-mail em domínio de exemplo 'exemplo.com.br'), portanto não há trajetória profissional pública confirmável. O cargo de Diretora de Engenharia é tratado como informação declarada no formulário do lead, e não como fato confirmado por fontes externas. A avaliação de relevância baseia-se no peso típico desse cargo (decisor/influenciador-chave técnico) dentro de uma organização de grande porte como o Nubank."
  },
  "dados empresa": {
    "nome empresa": "Nubank (razão social: Nu Holdings Ltd.)",
    "setor": "Serviços Financeiros - Fintech / Banco digital (neobank). Atua em serviços financeiros e meios de pagamento, regulado e supervisionado pelo Banco Central do Brasil.",
    "porte": 10000,
    "faturamento": 16300000000.0,
    "presenca_mercado": 10
  },
  "pontuacao lead": {
    "pontuacao": 94,
    "critérios": [
      "Relevância do cargo (peso 30%): cargo de Diretora de Engenharia - nota 9/10. Justificativa: alto poder de influência técnica e de decisão sobre arquitetura, stack e ferramentas de IA; forte influência sobre orçamento técnico; caso de uso declarado (automação de atendimento ao cliente e análise de dados) perfeitamente alinhado à dor de uma Diretoria de Engenharia em fintech de grande porte; poder de veto/endosso praticamente condicional. Não é 10 por não ser, necessariamente, o detentor final do orçamento (papel tipicamente do CTO/CFD).",
      "Porte da empresa (peso 25%): Nubank é uma corporação multinacional de grande porte, com aproximadamente 10.000 funcionários (dados de 2025; fontes recentes citam ~9.500 colaboradores em 2026) - nota 10/10. Justificativa: porte atende plenamente ao ICP da CrewAI (grandes empresas interessadas em automação com agentes de IA).",
      "Presença de mercado (peso 25%): nota 10/10. Justificativa: maior banco digital da América Latina e maior banco digital em número de clientes fora da Ásia; mais de 140 milhões de clientes (Brasil, México, Colômbia e EUA); fundada em 2013, sede em São Paulo; IPO em dezembro de 2021 (avaliada em US$ 45 bi à época, já negociada por volta de US$ 66 bi em avaliações recentes - NYSE: NU / B3: R0X034); investidores de peso (Sequoia Capital, Berkshire Hathaway, Tencent, Tiger Global, Goldman Sachs, Founders Fund); expansão internacional ativa (aprovação condicional para atuar como banco nos EUA em 2026 e avanços no México e Colômbia); pioneirismo em IA generativa (parceria com a OpenAI desde 2023/2025) para atendimento e crédito; solidez financeira (lucrativa, com receita anual de US$ 16,3 bilhões e lucro líquido de US$ 2,87 bilhões em 2025; receita de ~US$ 11,5 bilhões em 2024).",
      "Afinidade cultural (peso 20%): nota 8,6/10 (nota de afinidade cultural geral consolidada). Justificativa: forte convergência de valores entre CrewAI e Nubank - combate à complexidade (missão do Nubank) versus pilar 'Simplicity / Complexity Support' da CrewAI; inovação e inconformismo com o status quo; eficiência inteligente orientada a dados e escala; senso de propriedade/autonomia; centralidade da IA na estratégia de ambas. A nota não é 10 por três razões: (1) assimetria de estágio e maturidade (bank regulado e maduro x scale-up ágil, exigindo trabalho de conformidade/enterprise-readiness); (2) sobreposição parcial com"
    ]
  }
}
```

Na tela: JSON estruturado com 'pontuacao': 94 telas/27_exec_resposta_nota.png

A resposta vem em JSON, um formato de dados estruturado, seguindo o molde do Pydantic. Nota: noventa e quatro, com o peso de cada critério. Passou no filtro com folga.



```
Agent: Redator de E-mails

Task: Escreva um e-mail altamente personalizado usando o nome do lead, o cargo, as informações da empresa e qualquer conquista pessoal ou da empresa que seja relevante. O e-mail deve falar diretamente dos interesses do lead e das necessidades da empresa dele. Não é um contato "frio"; é um retorno a um formulário que o lead preencheu, então seja breve e direto. Não use saudações nem despedidas, e evite frases muito complexas. Nossa empresa e nosso produto: - Empresa: CrewAI - Produto: Plataforma de Orquestração de Múltiplos Agentes - Cliente ideal (ICP): grandes empresas interessadas em automação com agentes de IA. - Proposta: somos uma plataforma que permite orquestrar agentes de IA para automatizar processos em qualquer setor. Use as seguintes informações: Dados pessoais: {'nome': 'Carla Mendes (pessoa fictícia)', 'cargo': 'Diretora de Engenharia', 'relevancia cargo': 9, 'historico profissional': 'Não disponível/não verificável. O lead 'Carla Mendes' está explicitamente marcado como pessoa fictícia nos dados de cadastro (e-mail em domínio de exemplo 'exemplo.com.br'), portanto não há trajetória profissional pública confirmável. O cargo de Diretora de Engenharia é tratado como informação declarada no formulário do lead, e não como fato confirmado por fontes externas. A avaliação de relevância baseia-se no peso típico desse cargo (decisor/influenciador-chave técnico) dentro de uma organização de grande porte como o Nubank.'} Dados da empresa: {'nome empresa': 'Nubank (razão social: Nu Holdings Ltd.)', 'setor': 'Serviços Financeiros - Fintech / Banco digital (neobank). Atua em serviços financeiros e meios de pagamento, regulado e supervisionado pelo Banco Central do Brasil.', 'porte': 10000, 'faturamento': 16300000000.0, 'presenca_mercado': 10} Pontuação do lead: {'pontuacao': 94, 'critérios': ['Relevância do cargo (peso 30%): cargo de Diretora de Engenharia - nota 9/10. Justificativa: alto poder de influência técnica e de decisão sobre arquitetura, stack e ferramentas de IA; forte influência sobre orçamento técnico; caso de uso declarado (automação de atendimento ao cliente e análise de dados) perfeitamente alinhado à dor de uma Diretoria de Engenharia em fintech de grande porte; poder de veto/endosso praticamente condicional. Não é 10 por não ser, necessariamente, o detentor final do orçamento (papel tipicamente do CTO/CFD).', 'Porte da empresa (peso 25%): Nubank é uma corporação multinacional de grande porte, com aproximadamente 10.000 funcionários (dados de 2025; fontes recentes citam ~9.500 colaboradores em 2026) - nota 10/10. Justificativa: porte atende plenamente ao ICP da CrewAI (grandes empresas interessadas em automação com agentes de IA).', 'Presença de mercado (peso 25%): nota 10/10. Justificativa: maior banco digital da América Latina e maior banco digital em número de clientes fora da Ásia; mais de 140 milhões de clientes (Brasil, México, Colômbia e EUA); fundada em 2013, sede em São Paulo; IPO em dezembro de 2021 (avaliada em US$ 45 bi à época, já negociada por volta de US$ 66 bi em avaliações recentes - NYSE: NU / B3: R0X034); investidores de peso (Sequoia Capital, Berkshire Hathaway, Tencent, Tiger Global, Goldman Sachs, Founders Fund); expansão internacional ativa (aprovação condicional para atuar como banco nos EUA em 2026 e avanços no México e Colômbia); pioneirismo em IA generativa (parceria com a OpenAI desde 2023/2025) para atendimento e crédito; solidez financeira (lucrativa, com receita anual de US$ 16,3 bilhões e lucro líquido de US$ 2,87 bilhões em 2025; receita de ~US$ 11,5 bilhões em 2024).', 'Afinidade cultural (peso 20%): nota 8,6/10 (nota de afinidade cultural geral consolidada). Justificativa: forte convergência de valores entre CrewAI e Nubank - combate à complexidade (missão do Nubank) versus pilar 'Simplicity / Complexity Support' da CrewAI; inovação e inconformismo com o status quo; eficiência inteligente orientada a dados e escala; senso de propriedade/autonomia; centralidade da IA na estratégia de ambas. A nota não é 10 por três razões: (1) assimetria de estágio e maturidade (bank regulado e maduro x scale-up ágil, exigindo trabalho de conformidade/enterprise-readiness); (2) sobreposição parcial com"
    ]
  }
}
```

Na tela: Redator de E-mails recebendo os dados qualificados telas/28_exec_redator_email.png

Com nota acima de setenta, o fluxo aciona a segunda equipe, e o redator começa a escrever.

```
[Finalize] todos_count=0, todos_with_results=0
```

Agent: Especialista em Otimização de Engajamento

Final Answer:
Carla, você citou dois casos no formulário: automação de atendimento e análise de dados. Em uma operação como a do Nubank – 140 milhões de clientes, quatro países, US\$ 16,3 bilhões de receita, supervisão do Banco Central – isso não se resolve com um modelo isolado. Resolve-se com orquestração.

****Quer ver isso desenhado dentro do Nubank? Reserve 20 minutos aqui: [Link de agendamento].**

A CrewAI orquestra múltiplos agentes de IA para rodar processos de ponta a ponta. Em vez de um agente genérico, você monta times com papéis, ferramentas e regras próprias: um para triagem de atendimento, outro para cruzar dados, outro para validar compliance. Cada decisão fica rastreável.

Três pontos que pesam em times de engenharia como o seu:

- ****Camada de orquestração, não substituto.**** A CrewAI roda sobre os modelos que o Nubank já usa, inclusive os da OpenAI.
- ****Segurança, governança e auditoria**** pensadas desde o início para ambientes regulados.
- ****Escala sem inflar o time de engenharia.****

Bancos digitais já usam a CrewAI para reduzir tempo de resolução no atendimento e encurtar pipelines de análise – os dois casos que você declarou.

****Próximo passo em 2 cliques:**** escolha um horário nesta semana: [Link de agendamento]. Se preferir, respondo com duas opções agora mesmo – basta me dizer "manda os horários".

Uma pergunta rápida antes: qual dos dois casos é prioridade para o próximo trimestre? Sua resposta já direciona o recorte da conversa.

Task Completed
Name: Revise o rascunho do e-mail personalizado e otimize-o com CTAs fortes e ganchos de engajamento. Lembre-se de que o lead entrou em contato e preencheu um formulário. Seja breve e direto. Não use saudações nem despedidas, e evite frases muito complexas. Garanta que o e-mail incentive o lead a agendar uma reunião *qui, domo e munda, no fim, do cel todo, o modo e o tempo*

Na tela: 'Agent Final Answer' do Especialista em Engajamento telas/29_exec_email_final.png

O especialista em engajamento entrega a versão final: direta, personalizada e com uma chamada clara para agendar uma reunião.

13. Uso de tokens e custo

Todo LLM cobra por **token** (pedaços de palavras), tanto do texto enviado (*prompt*) quanto do texto gerado (*completion*). O CrewAI soma o consumo de cada crew em `token_usage`.

Abaixo transformamos esses números numa tabela e estimamos o custo. O **preço por milhão de tokens é um valor de exemplo**: confira a tabela atual do provedor que você estiver usando e ajuste a variável.

```
[12]: import pandas as pd

# Preço de EXEMPLO em dólares por 1 milhão de tokens: ajuste conforme o seu provedor
PRECO_POR_MILHAO_TOKENS_USD = 0.15

# Consumo da crew de qualificação (primeiro lead)
uso_qualificacao = pd.DataFrame([fluxo.state["resultados_qualificacao"][0].token_usage.model_dump()])

custo = PRECO_POR_MILHAO_TOKENS_USD * uso_qualificacao["total_tokens"].sum() / 1_000_000
print(f"Crew de qualificação: custo estimado de US$ (custo:.4f)"
      uso_qualificacao)

Crew de qualificação: custo estimado de US$ 0.0247
```

	total_tokens	prompt_tokens	cached_prompt_tokens	completion_tokens	reasoning_tokens	cache_creation_tokens	successful_requests
0	164667	135882		54528	28785	6708	21

```
[13]: # Consumo da crew de e-mail (primeiro lead aprovado)
if emails:
    uso_email = pd.DataFrame([emails[0].token_usage.model_dump()])
    custo = PRECO_POR_MILHAO_TOKENS_USD * uso_email["total_tokens"].sum() / 1_000_000
    print(f"Crew de e-mail: custo estimado de US$ (custo:.4f)"
          uso_email)
else:
    print("Nenhum lead passou do filtro (nota > 70), então a crew de e-mail não rodou.")

Crew de e-mail: custo estimado de US$ 0.0179
```

	total_tokens	prompt_tokens	cached_prompt_tokens	completion_tokens	reasoning_tokens	cache_creation_tokens	successful_requests
0	119638	97110		37120	22528	6184	18

Na tela: Tokens de cada crew (164.667 e 119.638) e o custo estimado com preço de exemplo telas/31_custos.png

Os modelos cobram por token, um pedaço de palavra, contando o texto enviado e o gerado. Foram cerca de cento e sessenta e cinco mil tokens na qualificação e cento e vinte mil no e-mail. Com o preço de exemplo da célula, isso dá uns quatro centavos de dólar.

Atributo		Valor
Nome	Carla Mendes (pessoa fictícia)	
Cargo	Diretora de Engenharia	
Relevância do cargo	9	
Histórico profissional	Não disponível/não verificável. O lead 'Carla Mendes' está explicitamente marcado como pessoa fictícia nos dados de cadastro (e-mail em domínio de exemplo 'exemplo.com.br'), portanto não há trajetória profissional pública confirmável. O cargo de Diretora de Engenharia é tratado como informação declarada no formulário do lead, e não como fato confirmado por fontes externas. A avaliação de relevância baseia-se no peso típico desse cargo (decisor/influenciador-chave técnico) dentro de uma organização de grande porte como o Nubank.	
Empresa	Nubank (razão social: Nu Holdings Ltd.)	
Setor	Serviços Financeiros — Fintech / Banco digital (neobank). Atua em serviços financeiros e meios de pagamento, regulado e supervisionado pelo Banco Central do Brasil.	
Porte (funcionários)	10000	
Faturamento	16300000000.000000	
Presença de mercado	10	
Nota do lead	94	
Relevância do cargo (peso 30%): cargo de Diretora de Engenharia — nota 9/10. Justificativa: alto poder de influência técnica e de decisão sobre arquitetura, stack e ferramentas de IA; forte influência sobre orçamento técnico; caso de uso declarado (automação de atendimento ao cliente e análise de dados) perfeitamente alinhado à dor de uma Diretoria de Engenharia em fintech de grande porte; poder de veto/endosso praticamente condicional. Não é 10 por não ser, necessariamente, o detentor final do orçamento (papel tipicamente do CTO/CFO). Porte da empresa (peso 25%): Nubank é uma corporação multinacional de grande porte, com aproximadamente 10.000 funcionários (dados de 2025; fontes recentes citam ~9.500 colaboradores em 2026) — nota 10/10. Justificativa: porte atende plenamente ao ICP da CrewAI (grandes empresas interessadas em automação com agentes de IA). Presença de mercado (peso 25%): nota 10/10. Justificativa: maior banco digital da América Latina e maior banco digital em número de clientes fora da Ásia; mais de 140 milhões de clientes (Brasil, México, Colômbia e EUA); fundada em 2013, sede em São Paulo; IPO em dezembro de 2021 (avaliada em US\$ 45 bi à época, já negociada por volta de US\$ 66 bi em avaliações recentes — NYSE: NU / B3: ROX034); investidores de peso (Sequoia Capital, Berkshire Hathaway, Tencent, Tiger Global, Goldman Sachs, Founders Fund); expansão internacional ativa (aprovação condicional para atuar como banco nos EUA em 2026 e avanços no México e Colômbia); pioneirismo em IA generativa (parceria com a OpenAI desde 2023/2025) para atendimento e crédito; solidez financeira (lucrativa, com receita anual de US\$ 16,3 bilhões e lucro líquido de US\$ 2,87 bilhões em 2025; receita de ~US\$ 11,5 bilhões em 2024). Afinidade cultural (peso 20%): nota 8,6/10 (nota de afinidade cultural geral consolidada). Justificativa: forte convergência de valores entre CrewAI e Nubank — combate à complexidade (missão do Nubank) versus pilar 'Simplicity / Complexity Support' da CrewAI; inovação e inconformismo com o status quo; eficiência inteligente orientada a dados e escala; senso de propriedade/autonomia; centralidade da IA na estratégia de ambas. A nota não é 10 por três razões: (1) assimetria de estágio e maturidade (bank regulado e maduro x scale-up ágil, exigindo trabalho de conformidade/enterprise-readiness); (2) sobreposição parcial com incumbente de IA (OpenAI), exigindo posicionamento da CrewAI como camada complementar de orquestração; (3) contato fictício não validado, impossibilitando confirmar o fit no nível individual. Aderência ao ICP e proposta de valor (embutida nos critérios acima): Nubank é grande empresa, líder de mercado, financeiramente sólida, com apetite e histórico comprovado de adoção de IA generativa; o caso de uso declarado (atendimento ao cliente + análise de dados) é exemplo ideal para orquestração de múltiplos agentes. Fit praticamente perfeito. Cálculo final (escala 0-100): (9 x 0,30) + (10 x 0,25) + (10 x 0,25) + (8,6 x 0,20) = 2,70 + 2,50 + 2,50 + 1,72 = 9,42 em escala 0-10.		
Crterios		

Na tela: Porte, setor, presença de mercado 10, nota 94 telas/33_tabela_lead_final.png

Com o Pydantic, montar esta tabela é só ler os campos: setor, cerca de dez mil funcionários, faturamento, presença de mercado e a nota noventa e quatro. Dados prontos para um CRM, o sistema que gerencia os clientes da empresa.

```
15. O e-mail gerado

Este é o resultado final do pipeline: o e-mail personalizado e otimizado pelos dois agentes da crew de e-mail. O texto está em .raw.

[15]: import textwrap

if emails:
    for paragrafo in emails[0].raw.split("\n"):
        print(textwrap.fill(paragrafo, width=90))
else:
    print("Nenhum e-mail foi gerado: o lead não passou do filtro (nota > 70).")

Carla, você citou dois casos no formulário: automação de atendimento e análise de dados.
Em uma operação como a do Nubank — 140 milhões de clientes, quatro países, US$ 16,3 bilhões de receita, supervisão do Banco Central — isso não se resolve com um modelo isolado. Resolve-se com orquestração.

**Quer ver isso desenhado dentro do Nubank? Reserve 20 minutos aqui: [Link de agendamento].

A CrewAI orquestra múltiplos agentes de IA para rodar processos de ponta a ponta. Em vez de um agente genérico, você monta times com papéis, ferramentas e regras próprias: um para triagem de atendimento, outro para cruzar dados, outro para validar compliance. Cada decisão fica rastreável.

Três pontos que pesam em times de engenharia como o seu:

- **Canadá de orquestração, não substituto.** A CrewAI roda sobre os modelos que o Nubank já usa, inclusive os da OpenAI.
- **Segurança, governança e auditoria** pensadas desde o início para ambientes regulados.
- **Escala sem inflar o time de engenharia.**

Bancos digitais já usam a CrewAI para reduzir tempo de resolução no atendimento e encurtar pipelines de análise — os dois casos que você declarou.

**Próximo passo em 2 cliques:** escolha um horário nesta semana: [Link de agendamento]. Se preferir, respondo com duas opções agora mesmo — basta me dizer "manda os horários".

Uma pergunta rápida antes: qual dos dois casos é prioridade para o próximo trimestre? Sua resposta já direciona o recorte da conversa.
```

Na tela: Texto completo do e-mail em português telas/34_email_gerado.png

E o produto final: o e-mail pronto para envio, com o nome da pessoa, os dados levantados, os casos de uso do formulário e uma chamada para ação.

16. Indo além: fluxos com condições e desvios

Um Flow pode ser bem mais sofisticado. Nesta versão usamos mais três recursos:

- **and_(a, b)**: a etapa só roda quando **as duas** etapas a e b terminarem (aqui, registrar_leads espera o filtro e o armazenamento).
- **or_(a, b)**: roda quando **qualquer uma** terminar (disponível, mas não usado aqui).
- **@router(etapa)**: um "desvio". O método devolve um **rótulo** (texto) e só as etapas com **@listen("rótulo")** são executadas.

Nosso roteador contar_leads escolhe o caminho pela quantidade de leads aprovados:

Quantidade	Rótulo	Caminho
mais de 10	"alto"	enviar direto para o CRM (Salesforce)
de 6 a 10	"medio"	repassar para o time de vendas
até 5	"baixo"	escrever os e-mails com a crew de e-mail

Dica: a anotação `>> Literal['alto', 'medio', 'baixo']` no roteador informa ao CrewAI quais rótulos ele pode devolver. Assim o diagrama consegue desenhar os três caminhos.

Cuidado: uma etapa que escuta um rótulo do roteador (`@listen('baixo')`) **não recebe os leads**. Ela é disparada pelo rótulo. Por isso `filtrar_leads` guarda os leads aprovados em `self.state["leads_aprovados"]`, e as etapas dos três caminhos leem de lá. O **estado** (`self.state`) é a "memória compartilhada" do fluxo.

```
[16]: from typing import Literal
from crewai.flow.flow import listen, start, and_, or_, router

class PipelineVendasCompleto(Flow):

    @start()
    def buscar_leads(self):
        # Exemplo fixo; num cenário real os leads viriam de um banco de dados
        leads = [
            {
                "dados_lead": {
                    "nome": "Carla Mendes (pessoa fictícia)",
                    "cargo": "Diretora de Engenharia",
                }
            }
        ]
```

Na tela: Tabela alto / medio / baixo e o aviso sobre self.state telas/35_router_explicacao.png

Para ir além: o `and` faz uma etapa esperar duas outras. O `router` é um desvio: devolve um rótulo, como alto, médio ou baixo, e só roda o caminho com aquele rótulo.

```
aprovados = [r for r in resultados if r['pontuacao_lead'].pontuacao > 70]
self.state["leads_aprovados"] = aprovados # guardado para os caminhos do roteador
return aprovados

@listen(and_(filtrar_leads, armazenar_pontuacoes))
def registrar_leads(self, leads):
    print(f"Leads registrados: {len(leads)}")

@router(filtrar_leads)
def contar_leads(self, resultados) -> Literal['alto', 'medio', 'baixo']:
    if len(resultados) > 10:
        return 'alto'
    elif len(resultados) > 5:
        return 'medio'
    else:
        return 'baixo'

# Atenção: quem escuta um rótulo do roteador recebe o RÓTULO (ex.: 'baixo'),
# não os leads. Por isso os leads aprovados são lidos do self.state.

@listen('alto')
def armazenar_no_salesforce(self):
    return self.state["leads_aprovados"]

@listen('medio')
def enviar_para_time_de_vendas(self):
    return self.state["leads_aprovados"]

@listen('baixo')
def escrever_email(self):
    leads = self.state["leads_aprovados"]
    leads_pontuados = [lead.to_dict() for lead in leads]
    emails = crew_redacao_email.kickoff_for_each(leads_pontuados)
    return emails

@listen(escrever_email)
def enviar_email(self, emails):
    # Aqui enviaremos os e-mails para os leads
    return emails
```


Visualizando o fluxo completo.

Na tela: `-> Literal['alto', 'medio', 'baixo']` e `self.state["leads_aprovados"]` telas/36_router_codigo.png

A anotação `Literal` lista os rótulos possíveis, para o diagrama desenhar os caminhos. E quem escuta um rótulo recebe só o rótulo; por isso os leads aprovados ficam no `state`.

Cena 35 Diagrama do fluxo completo

8:30 → 8:38 · 8 s



Na tela: Router contar_leads com três saídas tracejadas telas/37_diagrama_completo.png

No novo diagrama, as linhas vermelhas são o and, e as tracejadas são os três caminhos do router.

Cena 36 Resultado do fluxo completo

8:38 → 8:49 · 11 s

```
===== E-MAIL GERADO PELO FLUXO COMPLETO =====

Você já provou que o Nubank consegue construir agentes – o Nu AI Engine é a prova. O
problema agora é outro: coordenar dezenas deles em produção, com contexto compartilhado,
handoffs e auditoria de cada decisão.

Criar um agente é fácil. Fazer 50 deles trabalharem juntos sem virar caos operacional –
isso ninguém resolveu direito ainda.

Foi por isso que você preencheu o formulário apontando dois casos de uso: automação de
atendimento e análise de dados com agentes de IA. Com mais de 100 milhões de clientes,
isso deixa de ser piloto e vira problema de escala.

É exatamente aí que a CrewAI entra.

A CrewAI é a camada de orquestração que faz seus agentes – os que vocês já construíram e
os que vão construir – trabalharem juntos. Conecta ao que vocês já têm (engine
proprietário, OpenAI, Watsonx, Salesforce) e entrega enterprise-readiness: controle de
acesso, logs, rastreabilidade e deploy dentro do seu ambiente.

Para o Nubank, isso significa atendimento que resolve mais no primeiro contato e análises
em minutos, não em dias – sem furar conformidade.

**O próximo passo é simples:** me dá 20 minutos com seu time técnico e eu monto uma demo
com um fluxo igual ao de vocês – triagem de atendimento em múltiplos agentes e esteira de
análise de dados.

**Escolha um horário e eu confirmo hoje:**
👉 Terça, 10h
👉 Terça, 16h
👉 Quinta, 10h
👉 Quinta, 16h


Responde com o horário que funciona. Eu preparo o ambiente da demo antes da call – para
você ver funcionando, não slides.

Se nenhum desses encaixa, me manda duas opções da sua agenda e eu me adapto.
```

17. Resumo e exercícios

Na tela: E-mail gerado pelo caminho 'baixo' telas/38_fluxo_completo_email.png

Com um lead só, o router escolheu o caminho baixo e gerou um novo e-mail. O texto muda a cada execução, mas a estrutura se mantém.



Na tela: Lista do que vimos e os 5 exercícios [telas/39_resumo_exercicios.png](#)

Recapitulando: agentes com papel, objetivo e história; ferramentas para pesquisar na web; tarefas encadeadas com context; respostas estruturadas com Pydantic; e equipes orquestradas por um Flow. Agora é com vocês: troquem a empresa e o produto, adicionem leads e, como desafio, criem um agente que descubra leads sozinho. Até a próxima!